

# Enfoque Estadístico del Aprendizaje

Maestría en Explotación de Datos y el Descubrimiento de Conocimiento - UBA

Predicción de series temporales de producción de petróleo y gas en Argentina

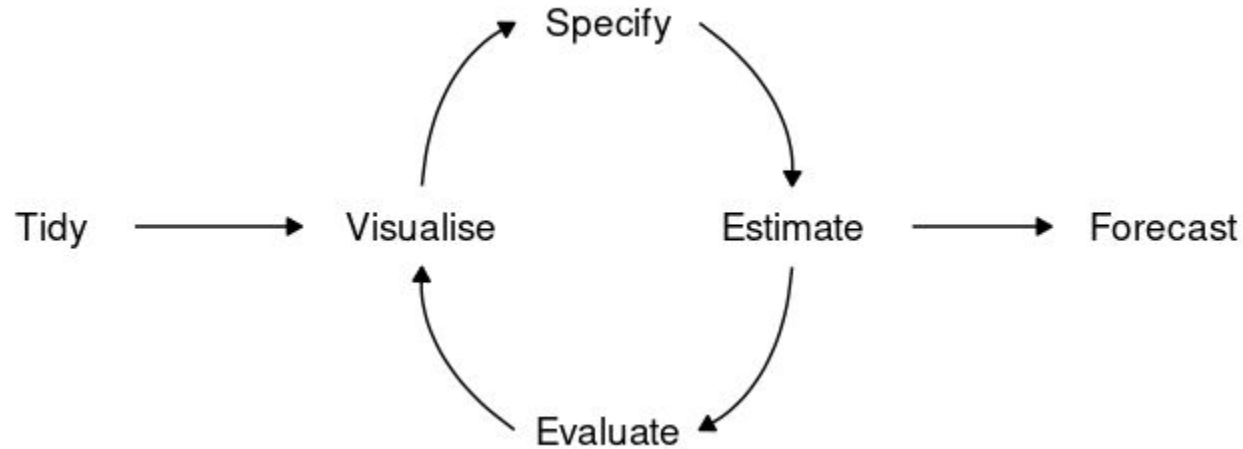
Autores:

- Baez, Lucas
- Pedersen, Sebastián
- Suster, Mateo

# Objetivos

- Modelar la evolución temporal de la producción petróleo y gas en Argentina
- Entender el resultado de las distintas predicciones
- Comparar las predicciones entre modelos

# Metodología



Fuente: Hyndman and Athanasopoulos (2021)

# Datos

- La Secretaría de Energía de la Nación publica información sobre los volúmenes de producción de hidrocarburos (gas y petróleo) por pozo de todo el país de manera mensual, entre otras variables (precios, inversiones, etc.)
- Tareas de preprocesamiento (concatenación, ajustes, etc.)
- Período contemplado: 2013 a 2020
  - Separación entre train y test



# Modelos

- Benchmarks
- STL
- Prophet
- Procesos gaussianos



# Referencias (I)

- Forecasting
  - [Hyndman, R.J., & Athanasopoulos, G. \(2021\) Forecasting: principles and practice, 3rd edition, OTexts: Melbourne, Australia](#)
- STL
  - [Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. J. \(1990\). STL: A seasonal-trend decomposition procedure based on loess. Journal of Official Statistics, 6\(1\).](#)
  - [Theodosiou, M. \(2011\). Forecasting monthly and quarterly time series using STL decomposition. International Journal of Forecasting, 27\(4\), 1178–1195](#)
  - [O'Hara-Wild \(2019\) Introducing feasts](#)
  - [Paquete R: fabletols](#)
- Prophet
  - [Harvey & Peters \(1990\). Estimation Procedures for Structural Time Series Models.](#)
  - [Barriola y Perini \(2021\). GAM en series de tiempo: Prophet. Nootebook de EEA](#)
  - [Librería Prophet para R](#)

# Referencias (II)

- Procesos Gaussianos

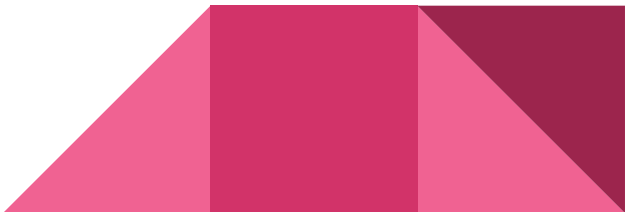
- [Robert B. Gramacy \(2021\). Surrogates: gaussian process modeling, design and optimization for the applied sciences.](#)
- [Felipe Tobar \(2021\). Aprendizaje de máquinas. Cap. 8: Procesos gaussianos.](#)
- [Carl E. Rasmussen, Christopher K. I. Williams \(2006\). Gaussian Processes for Machine Learning. MIT Press.](#)
- [Kevin P. Murphy \(2012\). Machine Learning: A Probabilistic Perspective. MIT Press. Ch. 15: Gaussian processes.](#)
- [Paquete de R, Kernlab \(Kernel-Based Machine Learning Lab\).](#)

# Modelos benchmark (I)

- **Mean method.** Predicción futura por medio de la media histórica de los datos

$$\hat{y}_{T+h|T} = \bar{y} = (y_1 + \cdots + y_T)/T.$$

- **Naïve method.** Predicción por última observación

$$\hat{y}_{T+h|T} = y_T.$$




# Modelos benchmark (II)

- **Seasonal naïve method.** Predicción por última observación de acuerdo a la estacionalidad del tiempo

$$\hat{y}_{T+h|T} = y_{T+h-m(k+1)},$$

- **Drift method.** Variación del método naïve, pero con cambios en el tiempo iguales a la variación promedio en los datos históricos

$$\hat{y}_{T+h|T} = y_T + \frac{h}{T-1} \sum_{t=2}^T (y_t - y_{t-1}) = y_T + h \left( \frac{y_T - y_1}{T-1} \right).$$

# Descomposición clásica de una serie temporal

- Componente de tendencia-ciclo ( $T_t$ )
    - Moving average
  - Componente estacional ( $S_t$ )
    - Promedio ajustado de la serie sin tendencia para cada estación
  - Componente remanente ( $R_t$ )
- Aditiva  $y_t = S_t + T_t + R_t,$
  - Multiplicativa  $y_t = S_t \times T_t \times R_t.$

## → Desventajas

- ◆ Patrón de estacionalidad constante en todos los períodos
- ◆ Imposibilidad de estimar una tendencia para las primeras y últimas observaciones
- ◆ No es robusta a datos atípicos

# STL

- Nombre de Seasonal and Trend decomposition using Loess
  - Loess (locally weighted smoothing): método no paramétrico
- Ventajas
  - Puede manejar cualquier tipo de estacionalidad
  - Componente estacional controlable y cambiante a lo largo del tiempo
  - Mayor flexibilidad y control del componente de tendencia-ciclo
  - Robustez ante outliers
  - Buen desempeño en series largas
- Desventajas
  - Dificultad de obtener descomposiciones multiplicativas (necesidad de aplicar transformaciones, e.g. Box - Cox)



# STL. Predicción

- **Idea general:** *dividir el problema de predicción en partes más pequeñas*
- Los **componentes de tendencia y estacionalidad** se predicen de manera separada
- Para estimar el **componente estacional** con cualquier método de forecasting no estacional
- A diferencia de la predicción por descomposición clásica, se modela el **componente remanente**

$$y_t = \hat{S}_t + \hat{A}_t,$$

Donde:

$$\hat{A}_t = \hat{T}_t + \hat{R}_t$$

# Prophet (Facebook)

- Librería desarrollada por Facebook para facilitar la tarea de creación de modelos predictivos en series temporales y detección de anomalías.
- En el fondo, es parte de la familia de los llamados modelos aditivos generalizados (GAM).




# Prophet (Facebook)

- Propone un modelo de la forma

$$y(t) = \text{trend}(t) + \text{seasonality}(t) + \text{holliday\_effects}(t)$$


Donde

- $\text{trend}(t)$ : Se compone de funciones lineales (o logísticas) a trozos que capturan las tendencias de la serie.
  - $\text{seasonality}(t)$ : Captura las tendencias periódicas.
  - $\text{holliday\_effects}(t)$ : Permite al usuario introducir momentos particulares o anómalos a priori para ajustar los modelos.
- 

# ¿Qué es un Proceso Gaussiano (PG)?

Problema de regresión: dado un conjunto de observaciones  $(x,y)$  busca encontrar un función  $f(x)=y$ .

$$\{(x_i, y_i)\}_{i=1}^N \longrightarrow y = f(x)$$



Regresión clásica: busca un único candidato de  $f$ .

Proceso Gaussiano: busca una distribución sobre la  $f$ .

$$\mathbb{P}(f) \quad f : \mathcal{X} \rightarrow \mathbb{R}.$$

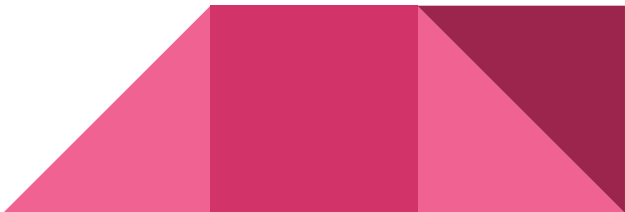
# ¿Qué es un Proceso Gaussiano (PG)?

Problema de regresión  $\{(x_i, y_i)\}_{i=1}^N \longrightarrow y = f(x)$

Proceso Gaussiano: busca una distribución sobre la  $f$ .

$$\mathbb{P}(f) \quad f : \mathcal{X} \rightarrow \mathbb{R}.$$

Para cualquier subconjunto  $\{x_i\}_{i=1}^n \subset \mathcal{X}$  la distribución de  $\mathbb{P}(f(\mathbf{x}))$  es una gaussiana multivariada  $f(\mathbf{x}) = (f(x_1), \dots, f(x_n))$





# ¿Qué es un Proceso Gaussiano (PG)?

Problema de regresión  $\{(x_i, y_i)\}_{i=1}^N \longrightarrow y = f(x)$

Proceso Gaussiano: busca una distribución sobre la  $f$ .

$$\mathbb{P}(f) \quad f : \mathcal{X} \rightarrow \mathbb{R}.$$

Para cualquier subconjunto  $\{x_i\}_{i=1}^n \subset \mathcal{X}$  la distribución de  $\mathbb{P}(f(\mathbf{x}))$  es una gaussiana multivariada  $f(\mathbf{x}) = (f(x_1), \dots, f(x_n))$

La gaussiana multivariada queda caracterizada por media y covarianza, las cuales suponemos dependen de  $\{x_i\}_{i=1}^n \subset \mathcal{X}$

$$f(\mathbf{x}) \sim \mathcal{N}(m(\mathbf{x}), K(\mathbf{x}, \mathbf{x}))$$

# ¿Qué es un Proceso Gaussiano (PG)?

Es normal asumir media cero en la normal multivariada.

Para la covarianza  $K$ , también llamada Kernel, hay que pedir que sea semi definida positiva (el análogo a pedir varianza positiva o cero en el caso univariado). Una elección popular es el kernel RBF (radial bases function):

$$K_{SE}(x, x') = \sigma^2 \exp \left( -\frac{(x - x')^2}{2\ell^2} \right) \quad \text{(si las obs. } x \text{ son vectores es la norma de la resta).}$$




# Sampleo de un PG (PG “prior”)

$$f(\mathbf{x}) \sim \mathcal{N}(m(\mathbf{x}), K(\mathbf{x}, \mathbf{x}))$$

Con media cero y  
kernel RBF.

Sampleamos tres  
veces para 200 valores  
de  $x$  equiespaciados  
entre 0 y 20:



# Incorporando información: posterior predicción sin ruido

Tenemos observaciones  $\{(x_i, f(x_i))\}_{i=1}^n$  y queremos realizar una predicción sobre un conjunto distinto  $X_*$  de  $m$  valores. Vale que:

$$\begin{bmatrix} f(X) \\ f(X_*) \end{bmatrix} \sim \mathcal{N} \left( \begin{bmatrix} m(X) \\ m(X_*) \end{bmatrix}, \begin{bmatrix} K(X, X) & K(X, X_*) \\ K(X_*, X) & K(X_*, X_*) \end{bmatrix} \right)$$

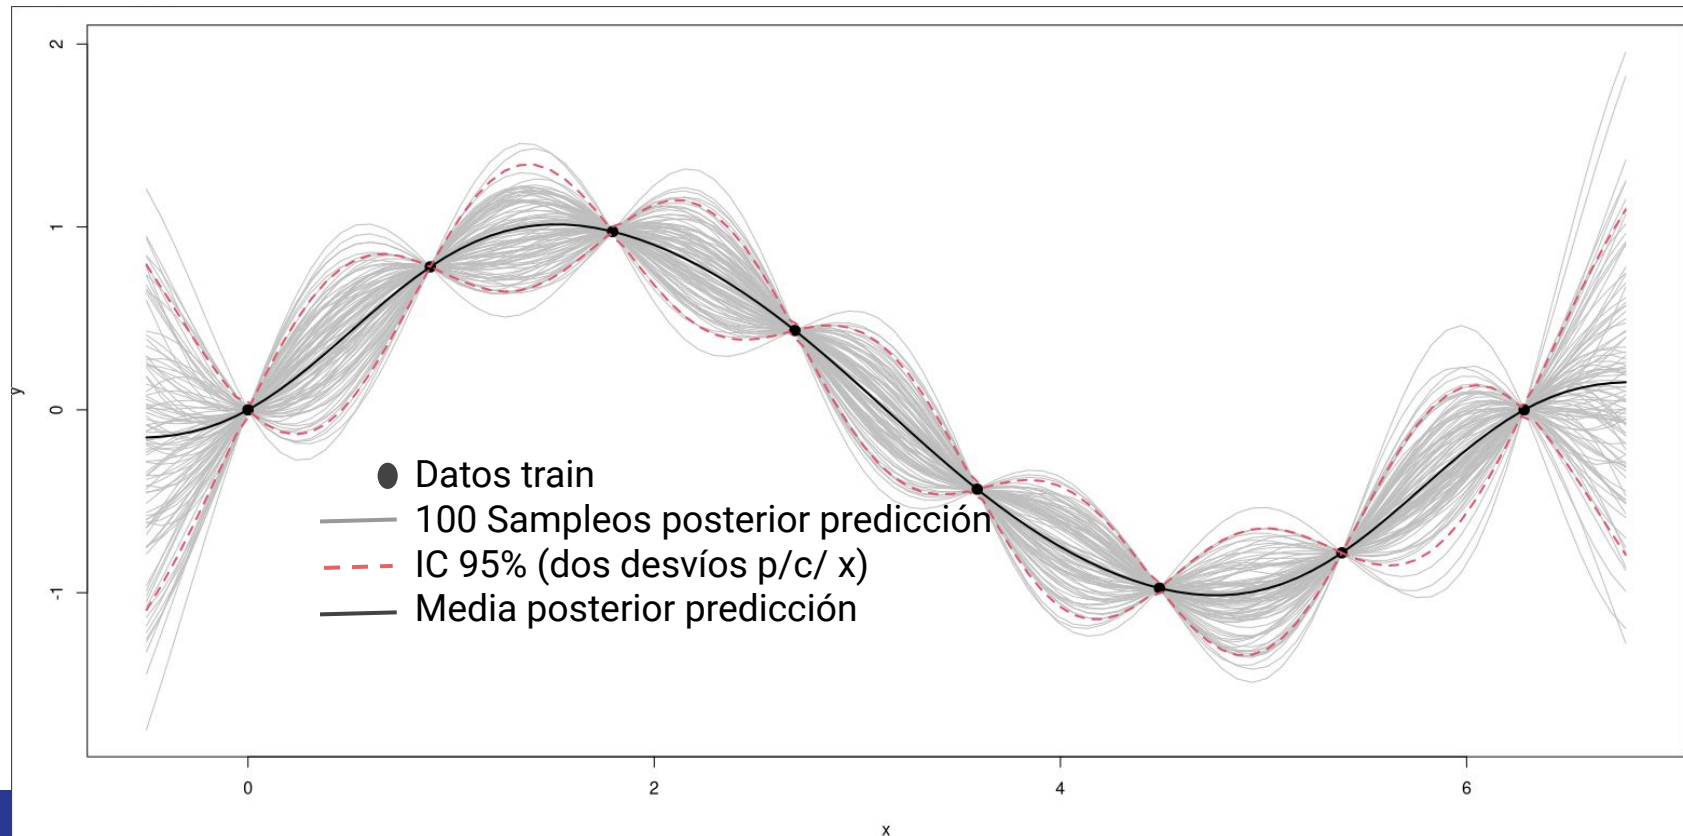
Y además la distrib. cond. nueva cumple:

$$f(X_*)|f(X), X \sim \mathcal{N}(m_{X_*|X}, \Sigma_{X_*|X}) \quad \begin{aligned} m_{X_*|X} &= m(X_*) + K(X_*, X)K^{-1}(X, X)(f(X) - m(X)) \\ \Sigma_{X_*|X} &= K(X_*, X_*) - K(X_*, X)K^{-1}(X, X)K(X, X_*) \end{aligned}$$

Es decir tenemos estas observaciones de datos, ponemos un PG prior, damos un rango donde queremos predecir, y obtenemos la distrib. posterior para predecir.

# Posterior predicción sin ruido: Ejemplo

$f(\mathbf{x}) \sim \mathcal{N}(m(\mathbf{x}), K(\mathbf{x}, \mathbf{x}))$ , con media cero y kernel RBF.



# Incorporando información: posterior predicción con ruido

Ahora tenemos datos con ruido  $y_i = f(x_i) + \eta$ ,  $\eta \sim \mathcal{N}(0, \sigma_n^2)$ . Es fácil ver que esto equivale a agregar un término a la diagonal de la covarianza:  $\text{cov}(Y) = K(X, X) + \sigma_n^2 \mathbb{I}$ . Análogo al caso anterior, vale que:

$$\begin{bmatrix} Y \\ f(X_*) \end{bmatrix} \sim \mathcal{N} \left( \begin{bmatrix} m(X) \\ m(X_*) \end{bmatrix}, \begin{bmatrix} K(X, X) + \sigma_n^2 \mathbb{I} & K(X, X_*) \\ K(X_*, X) & K(X_*, X_*) \end{bmatrix} \right)$$

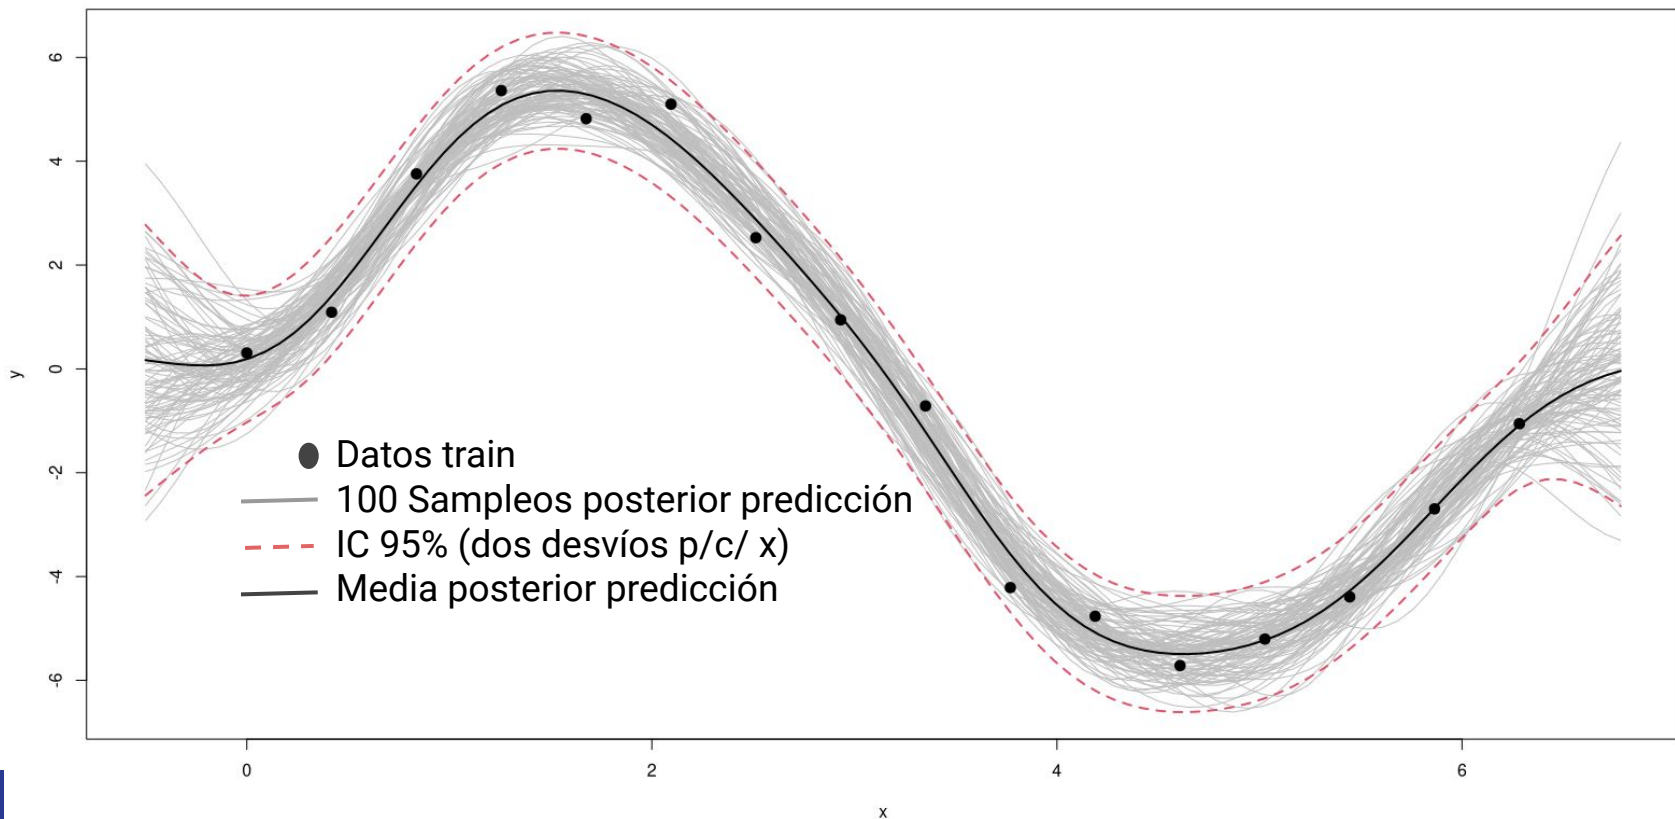
Y la distrib. cond. nueva cumple:

$$f(X_*)|Y, X \sim \mathcal{N}(m_{X_*|X}, \Sigma_{X_*|X}) \quad \begin{aligned} m_{X_*|X} &= m(X_*) + K(X_*, X)[K(X, X) + \sigma_n^2 \mathbb{I}]^{-1}(Y - m(X)) \\ \Sigma_{X_*|X} &= K(X_*, X_*) - K(X_*, X)[K(X, X) + \sigma_n^2 \mathbb{I}]^{-1}K(X, X_*) \end{aligned}$$

Nuevamente: datos train, prior,  
y obtenemos la posterior para predecir

# Posterior predicción con ruido: Ejemplo

$f(\mathbf{x}) \sim \mathcal{N}(m(\mathbf{x}), K(\mathbf{x}, \mathbf{x}))$ , con media cero y kernel RBF.



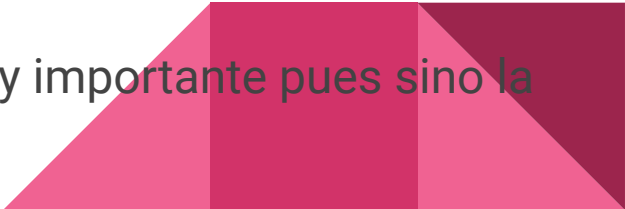
# Estimación de parámetros en PG.

Por supuesto es muy importante, antes de calcular y usar la posterior predicción, estimar los parámetros del modelo:

- Parámetros del Kernel
- Parámetro del ruido de las obs.
- Otros.

Popularmente se realiza mediante Máxima Verosimilitud, ya sea MLE o por inferencia bayesiana la distribución.

Ejemplo: estimar el parámetro de varianza del RBF es muy importante pues sino la posterior predicción puede estar subestimando el error.





# Algunas cosas más en PG.

- Más dimensiones: no mucho más que trabajar con normas en vez de módulos.
- Otros Kernels.

$$K_{RQ}(x, x') = \sigma^2 \left( 1 + \frac{(x - x')^2}{2\alpha\ell^2} \right)^{-\alpha}$$

$$K_P(x, x') = \sigma^2 \exp \left( -\frac{2 \sin^2 (\pi |x - x'|/p)}{\ell^2} \right)$$



# Aplicación datos reales hidrocarburos

